UNIVERSITÉ MOHAMMED PREMIER · FACULTÉ DES SCIENCES · OUJDA

Master Ingénierie Informatique · Module : Automatisation & IA Agentique · AY 2026–2027

CAHIER DES CHARGES OPÉRATIONNEL · PROJET M2 & CANDIDATURE RECHERCHE

ASSISTANT DE RECHERCHE MULTI-AGENTS AVEC RÉPONSES SOURCÉES (RAG MULTILINGUE)

Architecture Coopérative · Contrôle Contradictoire Anti-Hallucinations · Français, Anglais, Arabe

Stack : Python · LangGraph · FastAPI · ChromaDB · Embeddings Multilingues MPNet · Groq / Ollama

Auteur :	**Amine GHAYOUT** (Étudiant Master M2 Ingénierie Informatique)	**Date / Durée :**	Novembre 2026 · Sprint 4 semaines
Contact :	amineghayout7@gmail.com | +212 6 04 69 60 57	**Dépôt GitHub :**	https://github.com/Ghayout-Amine/multirag-agent
Objectif double :	Validation du module IA Agentique & Préparation technique directe au stage Cnam / Efrei 2027	**Cadre :**	Systèmes Multi-Agents & TAL Multilingue

1. Contexte et Problématique Centrale

Les modèles génératifs (LLM) sont sujets à des **hallucinations factuelles** et inventent fréquemment des sources. Cette vulnérabilité est critique en contexte scientifique et s'amplifie sur les langues peu dotées en données numériques. **Problématique :** *Comment concevoir un pipeline multi-agents asynchrone capable d'interroger un corpus documentaire multilingue (FR, EN, AR), de garantir un sourçage traçable à 100% et d'appliquer une abstention stricte en cas de manque de données ?*

2. Principes Directeurs et Périmètre d'Application

PÉRIMÈTRE INCLUS (Sprint de 4 semaines)	PÉRIMÈTRE EXCLU / EXTENSIONS DE STAGE
• Corpus structuré de ~80 notices d'autorité (FR/EN/AR) • 5 Agents spécialisés coordonnés par machine d'états (LangGraph) • Détection de langue automatique & Embeddings multilingues MPNet • Agent Vérificateur par inférence logique (NLI) anti-hallucination • API REST FastAPI documentée & Interface de test interactive • Banc d'essai de 30 requêtes évaluées avec ground truth & logs JSONL	• Entraînement / Fine-tuning de modèle de langue from scratch • Gestion multi-utilisateurs et système d'authentification RBAC • Stockage distribué IPFS & Identifiants décentralisés Web3 (DID / VC) • Contrats de réputation ERC-8004 & protocoles de micropaiement *(Ces éléments constituent le cœur du stage ultérieur au Cnam / Efrei)*

3. Architecture Multi-Agents et Modèle de Flux

Le système repose sur une orchestration cyclique d'agents spécialisés à responsabilités uniques. L'état de la requête (State Schema) est enrichi séquentiellement avec gestion d'erreurs et remédiation active.

Agent / Composant	Responsabilité Fonctionnelle	Entrée -> Sortie	Technologie
Agent 0 : Orchestrateur	Pilote la séquence, supervise les timeouts et déclenche la remédiation en cas de rejet par le vérificateur.	`Query -> Réponse finale validée`	LangGraph / Python
Agent 1 : Détection Langue	Identifie la langue de la question (fr, en, ar) ou lève une exception si non supportée.	`Texte brut -> Code ISO-639-1`	langdetect / lingua
Agent 2 : RAG Multilingue	Projette la requête dans l'espace vectoriel et extrait le Top-K passages (k=5, seuil cosinus tau >= 0.45).	`Vecteur 768d -> List[Chunk]`	ChromaDB + MPNet
Agent 3 : Réponse & Sourçage	Rédige la synthèse dans la langue détectée en liant obligatoirement chaque assertion à un extrait [1], [2].	`Chunks + Prompt -> Synthèse`	Gemini 3.5 Flash / API LLM
Agent 4 : Vérificateur (NLI)	Vérifie formellement la cohérence logique entre chaque assertion et son extrait source cité.	`(Assertion, Source) -> Bool`	LLM Entailment Check

4. Spécifications Détaillées des Modules

Module 1 — Constitution du Corpus et Indexation Vectorielle

• **Corpus de référence trilingue :** Histoire, géographie et patrimoine arabo-maghrébin (60 notices : 20 FR, 20 EN, 20 AR).
• **Chunking & Métadonnées :** Découpage en passages glissants de 200 tokens avec 30 tokens d'overlap. Métadonnées indexées : chunk_id, source_url, titre, langue.
• **Modèle de Plongement :** sentence-transformers/paraphrase-multilingual-mpnet-base-v2 (768d), assurant la recherche sémantique croisée (cross-lingue).
• **Double Mode de Réponse :** Seuil strict (tau >= 0.40) pour réponse sourcée directe, et seuil intermédiaire (tau >= 0.25) pour la **désambiguïsation interactive** guidant l'utilisateur sur requêtes vagues.

Module 2 — Balisage Hermétique Anti-Injection & Règle d'Abstention

Pour interdire les attaques par injection de prompt indirecte, les passages du corpus sont encapsulés dans des balises XML strictes non exécutables :

```
<system_instructions>
Tu es un agent d'extraction factuelle. Rédige ta réponse en utilisant STRICTEMENT les extraits
ci-dessous.
Toute affirmation doit citer son extrait sous forme [n]. Il est strictement interdit d'extrapoler.
Si les extraits ne contiennent pas l'information, réponds exactement : 'Information non trouvée dans le
corpus.'
</system_instructions>
<context> <doc id='1'>...</doc> <doc id='2'>...</doc> </context> Question: {query}
```

Module 3 — Mécanisme de Décision de l'Agent Vérificateur

Pour chaque assertion indexée [n], l'Agent Vérificateur interroge le LLM avec une directive NLI (Natural Language Inference) : *'L'extrait [n] soutient-il formellement l'assertion ? Répondre par OUI ou NON.'*
• Si OUI pour toutes les assertions : la réponse est validée et transmise à l'utilisateur.
• Si NON (hallucination détectée) : l'Orchestrateur relance l'Agent 3 avec consigne de correction (max 1 itération). Si persistance de l'échec, le système refuse de répondre.

5. Protocole Expérimental d'Évaluation & Métriques

L'évaluation s'appuie sur un jeu de **30 questions de test calibrées** (10 FR, 10 EN, 10 AR) réparties en 24 questions documentées et 6 questions 'hors corpus' destinées à valider le comportement d'abstention stricte.

Métrique Évaluée	Définition & Mode de Calcul	Cible Attendue
Pertinence documentaire	Pourcentage de réponses fournissant l'information exacte demandée	**>= 85 %**
Fidélité au sourçage	Pourcentage de citations [n] corroborées par l'extrait source correspondant	**>= 95 %**
Taux d'hallucinations	Pourcentage de réponses contenant une assertion factuelle non présente dans le corpus	**<= 5 % (0 visé)**
Refus justifié (Abstention)	Pourcentage de questions hors corpus pour lesquelles le système refuse correctement	**100 % (6 / 6)**
Latence bout en bout	Durée totale du cycle de traitement (Détection + RAG + Génération + Vérification)	**< 4s (API Gemini) / < 25s (Local)**
Gain de vérification (A/B)	Comparaison quantitative des performances : Système standard vs Système avec Vérificateur	**Réduction prouvée**

6. Traçabilité Analytique et Journalisation JSONL

Chaque interaction utilisateur alimente le fichier logs/traces.jsonl pour assurer la reproductibilité et l'auditabilité :


```
{ "timestamp": "2026-11-20T14:10:05Z", "query": "Quels sont les royaumes numides ?", "lang": "fr",
"retrieval": { "chunks_retrieved": 3, "scores": [0.89, 0.81, 0.74], "latency_ms": 120 }, "generation": {
"text": "Les royaumes numides comprenaient les Massyles... [1][2]", "tokens": 48 }, "verification": {
"verdict": "ACCEPTED", "citations_checked": 2, "hallucinations": 0 }, "total_latency_ms": 2850 }
```


7. Matrice Technologique Retenue

Composant	Solution Retenue	Rôle & Justification
Langage	`Python 3.11+`	Écosystème standard en TALN et IA agentique.
API Backend	`FastAPI + Pydantic v2`	Endpoints REST asynchrones, validation de types stricte.
Orchestration	`LangGraph / Finite State Machine`	Gestion des cycles, mémoire d'état et remédiation conditionnelle.
Embeddings	`paraphrase-multilingual-mpnet-base-v2`	Plongement sémantique performant couvrant FR, EN et Arabe.
Base Vectorielle	`ChromaDB`	Indexation locale HNSW légère avec gestion des métadonnées.
Moteur d'Inférence	`Groq Cloud (Llama-3) / Ollama Local`	Vitesse d'exécution cloud gratuite et option souveraine locale.
Interface IHM	`Streamlit Web Dashboard`	Exploration interactive des sources et affichage des métriques.

8. Planning Opérationnel (Sprint de 4 Semaines)

Semaine	Objectifs & Activités Détaillées	Livrable Validé
Semaine 0 **Setup & POC**	• Initialisation du dépôt GitHub (structure conforme PEP8). • Benchmark du modèle d'embeddings MPNet sur corpus pilote (5 documents). • Validation de l'environnement Python et des clés d'API (Groq / Ollama).	Environnement de dev opérationnel & POC vectoriel validé
Semaine 1 **Corpus & RAG**	• Extraction et normalisation des 80 documents (30 FR, 30 EN, 20 AR). • Chunking (300 tokens), calcul des embeddings et persistance ChromaDB. • Développement de l'Agent de recherche sémantique avec filtrage cosinus.	Base vectorielle indexée & tests unitaires RAG validés
Semaine 2 **Agents & API**	• Implémentation des agents Détection Langue, Réponse et Vérificateur. • Assemblage du graphe d'orchestration LangGraph avec cycle de remédiation. • Développement des routes FastAPI et mise en place des logs traces.jsonl.	Serveur d'API fonctionnel & pipeline d'agents interconnecté
Semaine 3 **Éval & IHM**	• Interface Streamlit avec consultation des citations au clic. • Exécution du protocole de 30 questions et calcul formel des métriques. • Rédaction du rapport scientifique et préparation de la vidéo de démonstration.	Rapport final, code documenté & démonstrateur opérationnel

9. Matrice des Livrables Contractuels

- **L1 — Code source :** Dépôt GitHub public structuré avec tests unitaires pytest et requirements.txt scellé.
- **L2 — Corpus d'autorité :** 80 fiches documentaires normalisées avec métadonnées complètes.
- **L3 — Dataset de test :** 30 requêtes évaluées avec ground truth et annotations d'extraits cibles.
- **L4 — Fichier de traces :** logs/traces.jsonl consignant les inférences et décisions des agents.
- **L5 — Rapport scientifique :** Analyse comparative (avec vs sans agent vérificateur) et bilan des métriques.
- **L6 — Démonstrateur :** Interface web interactive prête pour démonstration en direct lors d'entretiens.

10. Gestion des Risques & Alignement avec le Stage Cnam/Efrei

Exigence du Stage Cnam/Efrei	Démonstration Concrète dans ce Projet	Positionnement à l'Entretien
Systèmes Multi-Agents	5 agents coopératifs orchestrés par machine d'états LangGraph.	Maîtrise pratique du paradigme agentique et de la séparation des rôles.
RAG Multilingue	Espace sémantique MPNet unifié couvrant FR, EN et Arabe.	Capacité démontrée sur le traitement multilingue et les langues peu dotées.
Règle d'or : 'Il n'invente rien'	Agent Vérificateur NLI avec boucle de rejet et métriques d'hallucinations.	Sens aigu de la rigueur scientifique et du contrôle de vérifiabilité.
Stack Python / FastAPI	Architecture logicielle propre, typage Pydantic et API documentée.	Autonomie immédiate sur le développement du prototype de recherche.
Démarche Scientifique	Évaluation chiffrée sur 30 questions et comparaison A/B avec/sans vérificateur.	Profil adapté à une poursuite possible en doctorat (thèse).

Synthèse de Valorisation pour l'Entretien :
Ce document et le code associé démontrent que le candidat est **opérationnel dès le premier jour** sur le cœur du stage (RAG, multi-agents, anti-hallucination). Les dimensions Web3 (DID, IPFS, blockchain) et le catalogue kabyle réel représentent précisément l'objet de recherche que le candidat s'engage à développer au sein du laboratoire.