FICHE DE SYNTHÈSE D'ENTRETIEN — MULTIRAG-AGENT

Guide de Soutenance Master 2 & Entretien de Stage de Recherche (Cnam / Efrei Paris)

Amine GHAYOUT — Université Mohammed Premier, Oujda

1. Vision Globale du Projet : Problème, Solution et Objectif

Le Problème constaté	Notre Solution Technique	L'Objectif Final
Les LLM généralistes (comme ChatGPT) **hallucinent**, citent de fausses sources et ne sont pas vérifiables. En entreprise ou recherche, une réponse erronée est inacceptable.	Un système **RAG Multi-Agents** à 5 agents spécialisés : recherche sémantique ChromaDB, modèle MPNet multilingue (FR/EN/AR), et **Agent Vérificateur NLI** anti-hallucination.	Délivrer des réponses **strictement sourcées [n]**, avec **100% de refus légitime** hors corpus et un double mode : synthèse directe ou désambiguïsation interactive.

La phrase clé pour l'entretien : *'Ce projet n'est pas un simple chatbot, mais un système RAG d'entreprise à tolérance zéro pour l'hallucination, capable d'aligner trois langues dans un espace vectoriel dense et de faire certifier chaque affirmation par un agent auditeur indépendant.'*

2. État d'Avancement Réel de la Feuille de Route (Roadmap)

Composant / Étape	Description technique & Rôle dans l'architecture	Statut Réel
Étape 0 : Données & CDC	Cahier des charges formel, modèles Pydantic (DocumentNotice, DocumentChunk) et dépôt Git.	**FAIT ■**
Étape 1 : Agent 1 (Langue)	Détection déterministe ISO-639-1 (FR, EN, AR) avec rejet précoce en 30ms des langues non supportées.	**FAIT ■ (4/4 tests)**
Étape 2 : Base Vectorielle	ChromaDB persistant + modèle Sentence-Transformers paraphrase-multilingual-mpnet-base-v2 (768d).	**FAIT ■**
Étape 3 : Agent 2 (Retriever)	Recherche sémantique cosinus avec double seuil : seuil strict (0.40) et seuil de désambiguïsation (0.25).	**FAIT ■ (4/4 tests)**
Étape 4 : Agent 3 (Réponse LLM)	Génération factuelle sourcée avec isolation hermétique XML (anti-injection) via Gemini 3.5 Flash Lite.	**FAIT ■ (3/3 tests)**
Étape 5 : Agent 4 (Vérificateur)	Audit NLI (Natural Language Inference) : découpe la réponse en assertions et bloque les faits non prouvés.	**FAIT ■ (100% fidélité)**
Étape 6 : Agent 0 (Orchestrateur)	Machine à états coordonnant les 4 agents avec calcul de latence et traçabilité d'audit de bout en bout.	**FAIT ■ (4/4 tests)**
Étape 7 : Corpus Étendu (60 fiches)	60 notices multilingues (20 FR, 20 EN, 20 AR) indexées sur l'histoire et le patrimoine arabo-maghrébin.	**FAIT ■ (60 notices)**
Étape 8 : Interface Web (Streamlit)	Application interactive locale : dialogue, cartes de métriques, affichage des sources [n] et boutons de choix.	**FAIT ■ (Opérationnel)**

3. Les 5 Questions Clés du Jury d'Entretien (et les Réponses Parfaites)

Voici les réponses techniques et scientifiques que vous devez donner pour impressionner les professeurs du Cnam / Efrei :

Q1. Pourquoi utiliser une architecture multi-agents au lieu d'un seul prompt envoyé à un LLM ?
Réponse candidat : *'Un LLM unique mélange la génération et son auto-évaluation : il a tendance à sur-confirmer ses propres erreurs. Dans notre architecture, nous appliquons le principe du **contrôle contradictoire** : l'Agent 4 (Vérificateur NLI) est indépendant de l'Agent 3 (Rédacteur). Il audite chaque affirmation par rapport aux textes sources bruts et peut rejeter ou forcer une révision si un fait n'est pas prouvé.'*

Q2. Pourquoi avez-vous choisi l'API Gemini de Google plutôt que Groq ou ChatGPT ?
Réponse candidat : *'Sur mon CV, il est indiqué LLM (Ollama / API). J'ai sélectionné l'API Gemini 3.5 Flash Lite via Google AI Studio pour trois raisons scientifiques : 1. Son **excellence sur le multilinguisme**, notamment le traitement croisé de l'arabe classique et du français ; 2. Sa grande vitesse d'inférence (latence ~1s) ; 3. Son intégration native sécurisée et gratuite pour un projet académique.'*

Q3. Pourquoi 60 fiches dans le corpus suffisent-elles ? N'est-ce pas trop limité par rapport à ChatGPT ?
Réponse candidat : *'Notre objectif n'est pas de refaire un moteur généraliste, mais de concevoir un système RAG d'entreprise à haute fidélité. Les 60 fiches (20 FR, 20 EN, 20 AR) constituent notre corpus de référence scientifique. Grâce au découplage de ChromaDB, une entreprise peut ajouter 10 000 fiches demain sans modifier une seule ligne de code ni réentraîner de modèle.'*

Q4. Pourquoi le système répond-il parfois par une liste directe et parfois par des boutons de choix ?
Réponse candidat : *'C'est notre module de **désambiguïsation interactive** : quand la requête est claire mais générale (ex: 'donner le nom de roi'), le système fait une synthèse multi-documents directe avec citations [1], [2]. Quand la requête est trop vague (ex: 'une grande bataille'), le système propose des boutons de clarification pour guider l'utilisateur sans deviner à sa place.'*

Q5. Comment mesurez-vous le taux d'hallucination et la fidélité de votre système ?
Réponse candidat : *'Chaque affirmation candidate est modélisée sous forme d'assertion atomique. L'Agent 4 effectue un test d'inférence logique (Entailment / Contradiction). Le score de fidélité est le ratio (affirmations prouvées / total assertions). Si le score est inférieur à 100%, l'alerte est levée et la réponse est bloquée ou corrigée.'*

4. Justification Technique des Fichiers Clés du Dépôt Git

Fichier	Rôle Technique	Valeur Ingénieur / Recherche
`src/rag/vector_store.py`	Gestionnaire ChromaDB + SentenceTransformers (MPNet). Découpage en chunks de 200 tokens avec overlap 30.	Indexation sémantique dense avec distance cosinus multilingue unifiée.
`src/agents/verifier_agent.py`	Agent 4 d'audit NLI produisant un verdict JSON strict (is_faithful, score, hallucinations).	Éradication active des hallucinations : prouve la fiabilité en environnement critique.
`src/agents/orchestrator.py`	Agent 0 machine à états coordonnant la séquence 1 → 2 → 3 → 4 avec traces d'exécution.	Traçabilité et observabilité complètes du pipeline d'agents.
`src/app.py`	Interface graphique Streamlit avec retour visuel, cartes de métriques et boutons d'aide.	Démonstrateur interactif prêt pour la présentation de soutenance en direct.

Conclusion pour l'Entretien : Ce projet prouve une maîtrise complète du cycle d'ingénierie de l'IA générative : de la modélisation formelle des données à l'évaluation expérimentale, en passant par l'élimination des hallucinations et le déploiement d'une interface graphique. Le candidat est immédiatement opérationnel pour un stage de recherche au Cnam / Efrei.